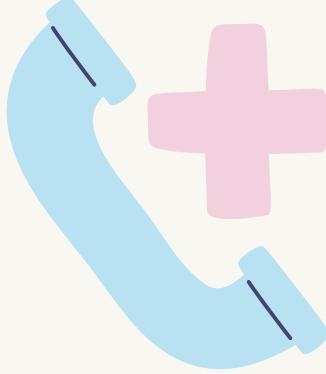




SYSTEME DE SURVEILLANCE DES DONNÉES DE PRESSION ARTERIELLE EN TEMPS REEL

Kafka - Elasticsearch - Kibana - Machine Learning

CHIAB Meriem et KACHOUR Amara



Contexte et objectif

01 Contexte

- Surveillance médicale continue
- Données de pression artérielle en temps réel
- Importance de la détection rapide des anomalies

02 Objectifs

- Mettre en place un pipeline temps réel
- Déetecter automatiquement les anomalies
- Visualiser et alerter via Kibana



SOMMAIRE

01 **Architecture globale du système**

04 **Intégration du modèle de Machine Learning**

07 **Système d'alertes en temps réel**

02 **Génération et streaming des données (Kafka)**

05 **Stockage et indexation des données**

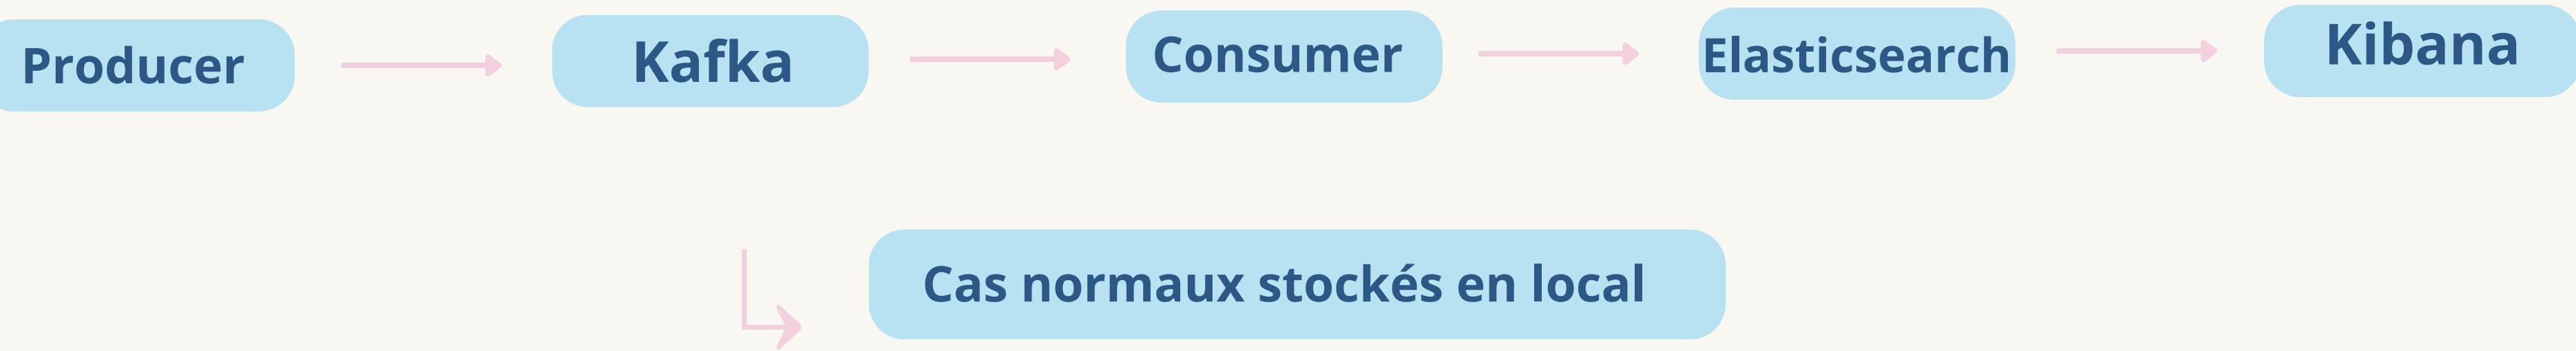
08 **Limites et perspectives d'amélioration**

03 **Traitement des données et détection des anomalies**

06 **Visualisation et dashboards Kibana**

09 **Conclusion**

01 Architecture global du système



02 Génération et streaming des données (Kafka)

```
import json
import time
from datetime import datetime, timezone
from faker import Faker
from kafka import KafkaProducer

# Générateur de valeurs réalistes
fake = Faker()

# Kafka
KAFKA_BROKER = "localhost:9092"
TOPIC = "blood_pressure_fhir"

# 5 patients fixes
PATIENT_IDS = ["PAT-001", "PAT-002", "PAT-003", "PAT-004", "PAT-005"]

# 2 practitioners fixes (soignants)
PRACTITIONER_IDS = ["PRAC-01", "PRAC-02"]

# Producteur Kafka : envoie des dict Python encodés en JSON
producer = KafkaProducer(
    bootstrap_servers=KAFKA_BROKER,
    value_serializer=lambda v: json.dumps(v).encode("utf-8"),
)

def now_iso():
    """Renvoie la date/heure actuelle en ISO 8601 (UTC)."""
    return datetime.now(timezone.utc).isoformat()
```

```
def build_fhir_observation(patient_id: str, practitioner_id: str) -> dict:
    """
    Crée une Observation FHIR (format simple).
    On inclut :
    - subject : Patient/...
    - performer : Practitioner/...
    - component : systolic + diastolic
    """
    systolic = fake.random_int(min=80, max=190)
    diastolic = fake.random_int(min=50, max=120)

    return {
        "resourceType": "Observation",
        "status": "final",
        "subject": {"reference": f"Patient/{patient_id}"},  
        "performer": [{"reference": f"Practitioner/{practitioner_id}"}],  
        "effectiveDateTime": now_iso(),  
        "component": [  
            {  
                "code": {"text": "Systolic Blood Pressure"},  
                "valueQuantity": {"value": systolic, "unit": "mmHg"},  
            },  
            {  
                "code": {"text": "Diastolic Blood Pressure"},  
                "valueQuantity": {"value": diastolic, "unit": "mmHg"},  
            },  
        ],
    }
```

```
if __name__ == "__main__":
    print("Producer started (5 patients / 2 practitioners / every 5 seconds)")
    idx = 0

    # Boucle infinie : toutes les 5 secondes, on envoie 5 messages (1 par patient)
    while True:
        for patient_id in PATIENT_IDS:
            # On alterne PRAC-01 / PRAC-02
            practitioner_id = PRACTITIONER_IDS[idx % len(PRACTITIONER_IDS)]
            idx += 1

            obs = build_fhir_observation(patient_id, practitioner_id)

            # Envoi vers Kafka
            producer.send(TOPIC, obs)
            print(f"Sent -> patient={patient_id} practitioner={practitioner_id}")

        # On force l'envoi immédiat du batch
        producer.flush()

        # Pause de 5 secondes
        time.sleep(5)
```

03 Traitement des données et détection des anomalies

```
# 2) OUTILS : EXTRACTION
#
def extract_fields(obs: dict):
    """
    Extrait les champs utiles depuis une Observation FHIR (ton format producer).
    - patient_id : subject.reference = "Patient/<id>"
    - practitioner_id : performer[0].reference = "Practitioner/<id>" (si présent)
    - systolic / diastolic : component[0] / component[1]
    - timestamp : effectiveDateTime
    """

    # patient
    patient_ref = obs.get("subject", {}).get("reference", "Patient/unknown")
    patient_id = patient_ref.split("/")[-1]

    # practitioner
    performer = obs.get("performer", [])
    if performer and isinstance(performer, list):
        prac_ref = performer[0].get("reference", "Practitioner/unknown")
        practitioner_id = prac_ref.split("/")[-1]
    else:
        practitioner_id = "unknown"

    # pression
    components = obs.get("component", [])
    systolic = int(components[0]["valueQuantity"]["value"])
    diastolic = int(components[1]["valueQuantity"]["value"])

    # temps
    ts = obs.get("effectiveDateTime")

    return patient_id, practitioner_id, systolic, diastolic, ts
```

```
# 3) OUTILS : RÈGLES + ML
#
✓ def classify_rules(sys_val: int, dia_val: int):
    """
    Règles simples (seuils du sujet):
    - systolique > 140 ou < 90
    - diastolique > 90 ou < 60

    Retour:
    - is_anomaly : bool
    - anomaly_type : "hypertension" / "hypotension" / "normal"
    - details : liste (tags précis)
    """
    details = []

    if sys_val > 140:
        details.append("hypertension_systolic")
    if sys_val < 90:
        details.append("hypotension_systolic")
    if dia_val > 90:
        details.append("hypertension_diastolic")
    if dia_val < 60:
        details.append("hypotension_diastolic")

    is_anomaly = len(details) > 0

    if not is_anomaly:
        anomaly_type = "normal"
    else:
        anomaly_type = "hypertension" if any("hyper" in d for d in details) else "hypotension"

    return is_anomaly, anomaly_type, details
```

```
✓ def predict_risk_ml(sys_val: int, dia_val: int):
    """
    Prédiction ML très simple :
    - pred : 0 (normal) ou 1 (anormal)
    - risk : probabilité d'anomalie (entre 0 et 1)
    """
    X = [[sys_val, dia_val]]
    pred = int(model.predict(X)[0])
    risk = float(model.predict_proba(X)[0][1])
    return pred, risk
```

04 Intégration du modèle de Machine Learning

```
# train_ml.py
import numpy as np
from sklearn.linear_model import LogisticRegression
from sklearn.model_selection import train_test_split
from sklearn.metrics import classification_report
import joblib

np.random.seed(42)

# 1) dataset simple : sys + dia
N = 5000
sys = np.random.normal(loc=120, scale=20, size=N)
dia = np.random.normal(loc=80, scale=15, size=N)

# 2) label = anomalie selon seuils cliniques
y = ((sys >= 140) | (sys <= 90) | (dia >= 90) | (dia <= 60)).astype(int)

# 3) X = features
X = np.column_stack([sys, dia])

# 4) split train/test
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y
)
```

```
# 5) modèle simple
model = LogisticRegression(max_iter=1000)
model.fit(X_train, y_train)

# 6) évaluation rapide
pred = model.predict(X_test)
print(classification_report(y_test, pred))

# 7) sauvegarde
joblib.dump(model, "bp_logreg.joblib")
print(" Modèle sauvégarde : bp_logreg.joblib")
```

05 Stockage et indexation des données

Stockage différencié :

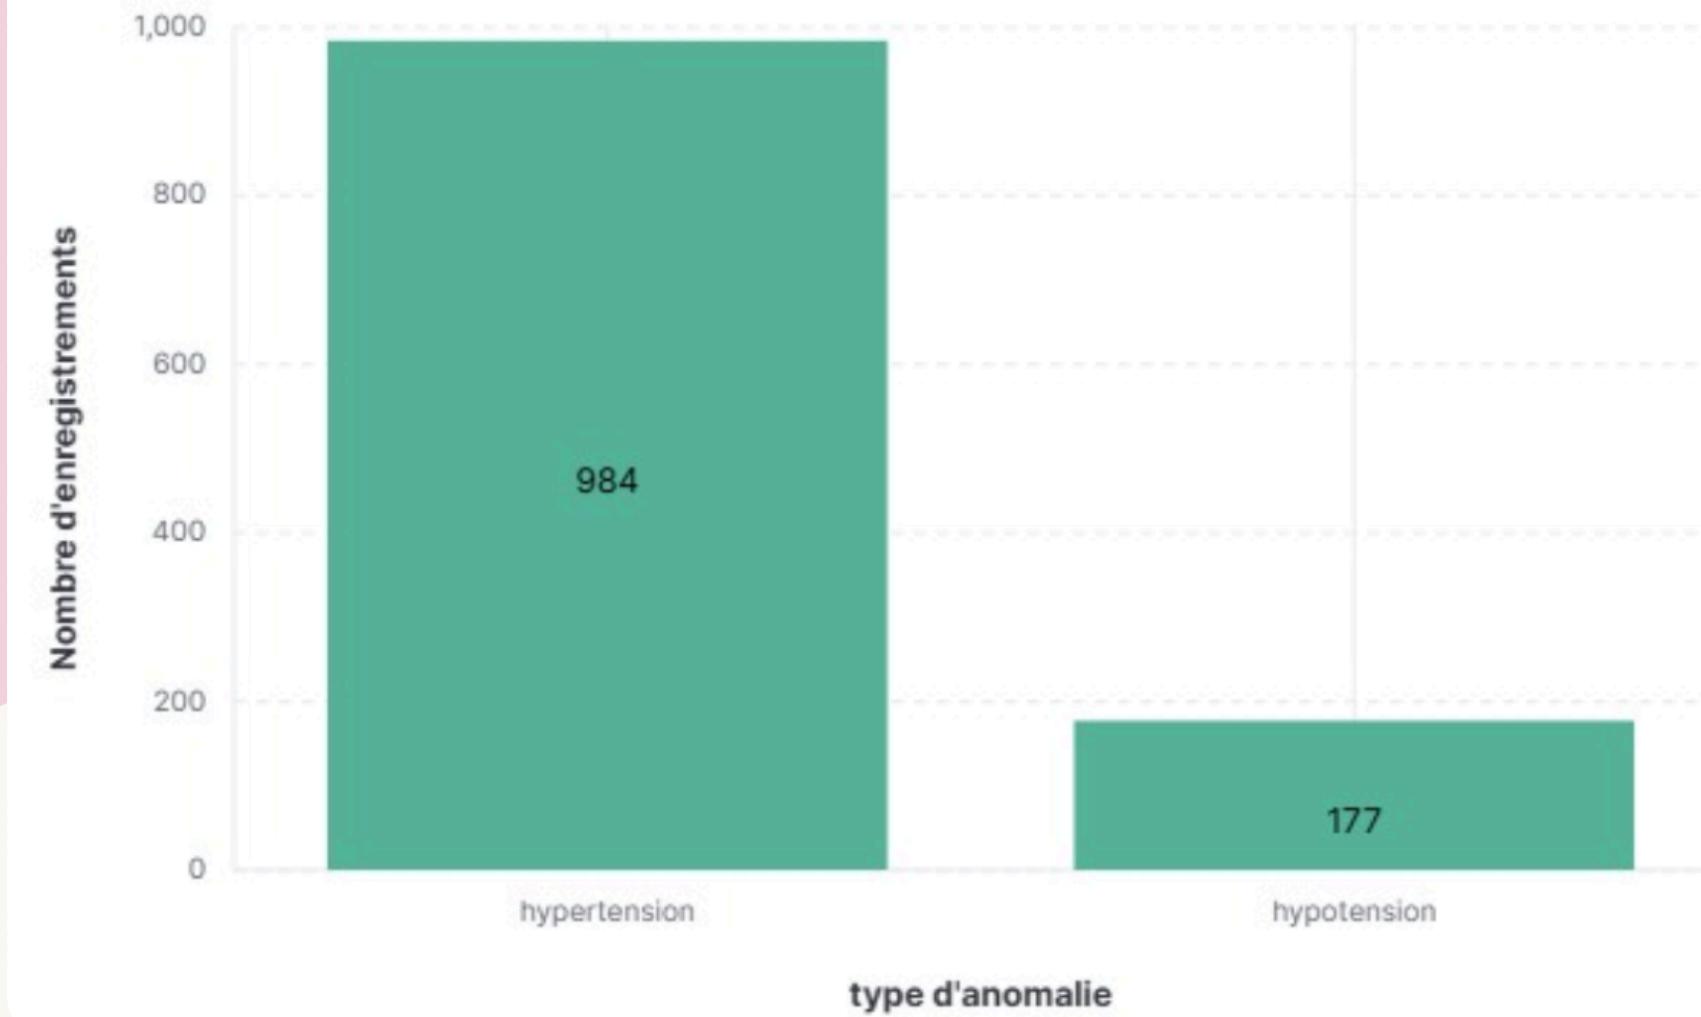
Anomalies → Elasticsearch

Données normales → fichiers JSON locaux

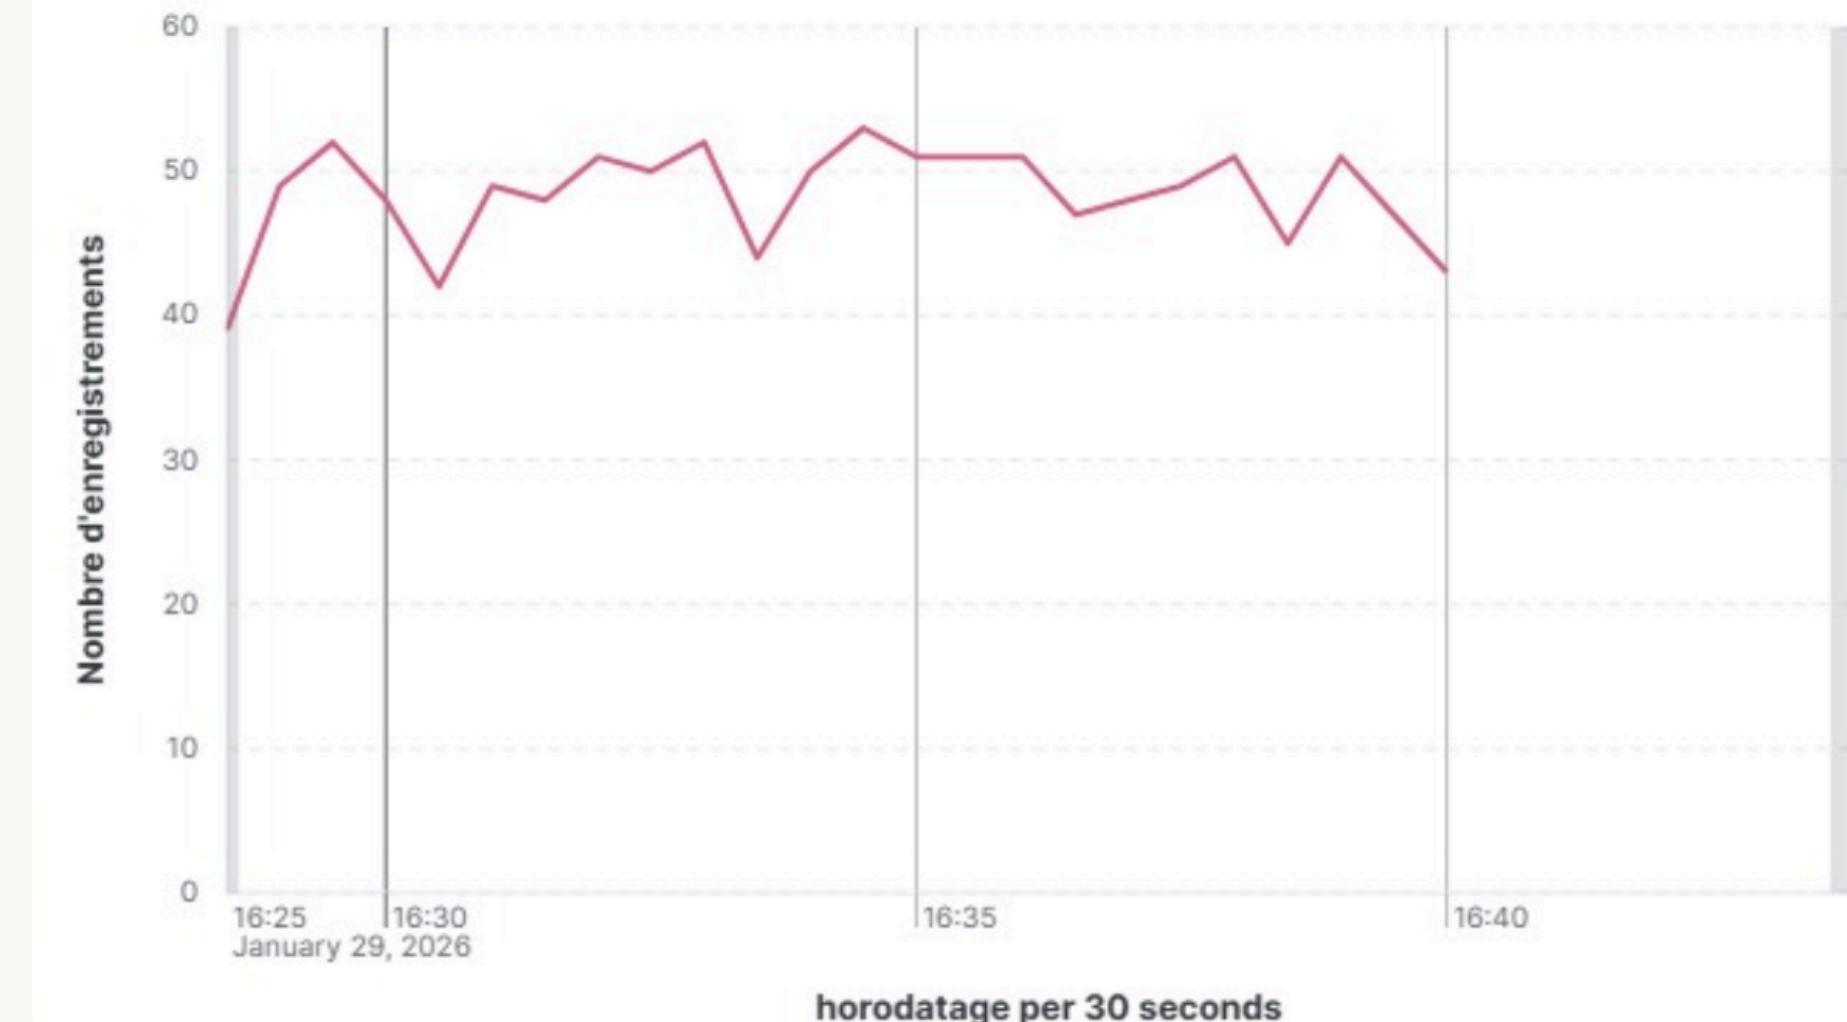
Nom	Modifié le	Type	Taille
PAT-003_PRAC-01_20260129_213251_6193...	29/01/2026 22:32	Fichier source JSON	1 Ko
PAT-005_PRAC-01_20260129_213241_7977...	29/01/2026 22:32	Fichier source JSON	1 Ko
PAT-001_PRAC-01_20260129_213231_2114...	29/01/2026 22:32	Fichier source JSON	1 Ko
PAT-004_PRAC-02_20260129_213231_4169...	29/01/2026 22:32	Fichier source JSON	1 Ko
PAT-005_PRAC-01_20260129_213231_4199...	29/01/2026 22:32	Fichier source JSON	1 Ko
PAT-001_PRAC-01_20260129_213220_9008...	29/01/2026 22:32	Fichier source JSON	1 Ko
PAT-003_PRAC-02_20260129_213215_9513...	29/01/2026 22:32	Fichier source JSON	1 Ko
PAT-005_PRAC-01_20260129_213211_0311...	29/01/2026 22:32	Fichier source JSON	1 Ko
PAT-001_PRAC-02_20260129_213205_7835...	29/01/2026 22:32	Fichier source JSON	1 Ko
PAT-002_PRAC-01_20260129_213205_7940...	29/01/2026 22:32	Fichier source JSON	1 Ko
PAT-003_PRAC-02_20260129_213205_7966...	29/01/2026 22:32	Fichier source JSON	1 Ko
PAT-004_PRAC-01_20260129_213205_7991...	29/01/2026 22:32	Fichier source JSON	1 Ko
PAT-005_PRAC-02_20260129_213205_8041...	29/01/2026 22:32	Fichier source JSON	1 Ko
PAT-001_PRAC-01_20260129_213200_7544...	29/01/2026 22:32	Fichier source JSON	1 Ko
PAT-004_PRAC-02_20260129_213200_8897...	29/01/2026 22:32	Fichier source JSON	1 Ko
PAT-001_PRAC-01_20260129_213150_7121...	29/01/2026 22:31	Fichier source JSON	1 Ko
PAT-004_PRAC-02_20260129_213150_8369...	29/01/2026 22:31	Fichier source JSON	1 Ko
PAT-004_PRAC-01_20260129_213145_8571...	29/01/2026 22:31	Fichier source JSON	1 Ko
PAT-003_PRAC-01_20260129_213140_7689...	29/01/2026 22:31	Fichier source JSON	1 Ko
PAT-002_PRAC-01_20260129_213135_7786...	29/01/2026 22:31	Fichier source JSON	1 Ko
PAT-002_PRAC-02_20260129_213130_6579...	29/01/2026 22:31	Fichier source JSON	1 Ko
PAT-003_PRAC-01_20260129_213130_6599...	29/01/2026 22:31	Fichier source JSON	1 Ko
PAT-001_PRAC-02_20260129_213125_5547...	29/01/2026 22:31	Fichier source JSON	1 Ko
PAT-004_PRAC-01_20260129_213125_6817...	29/01/2026 22:31	Fichier source JSON	1 Ko
PAT-002_PRAC-02_20260129_213120_6002...	29/01/2026 22:31	Fichier source JSON	1 Ko
PAT-004_PRAC-02_20260129_213120_6548...	29/01/2026 22:31	Fichier source JSON	1 Ko
PAT-002_PRAC-01_20260129_213105_5424...	29/01/2026 22:31	Fichier source JSON	1 Ko
PAT-003_PRAC-01_20260129_213050_5401...	29/01/2026 22:30	Fichier source JSON	1 Ko

06 Visualisation et dashboards Kibana

Répartition des types d'anomalies de pression artérielle

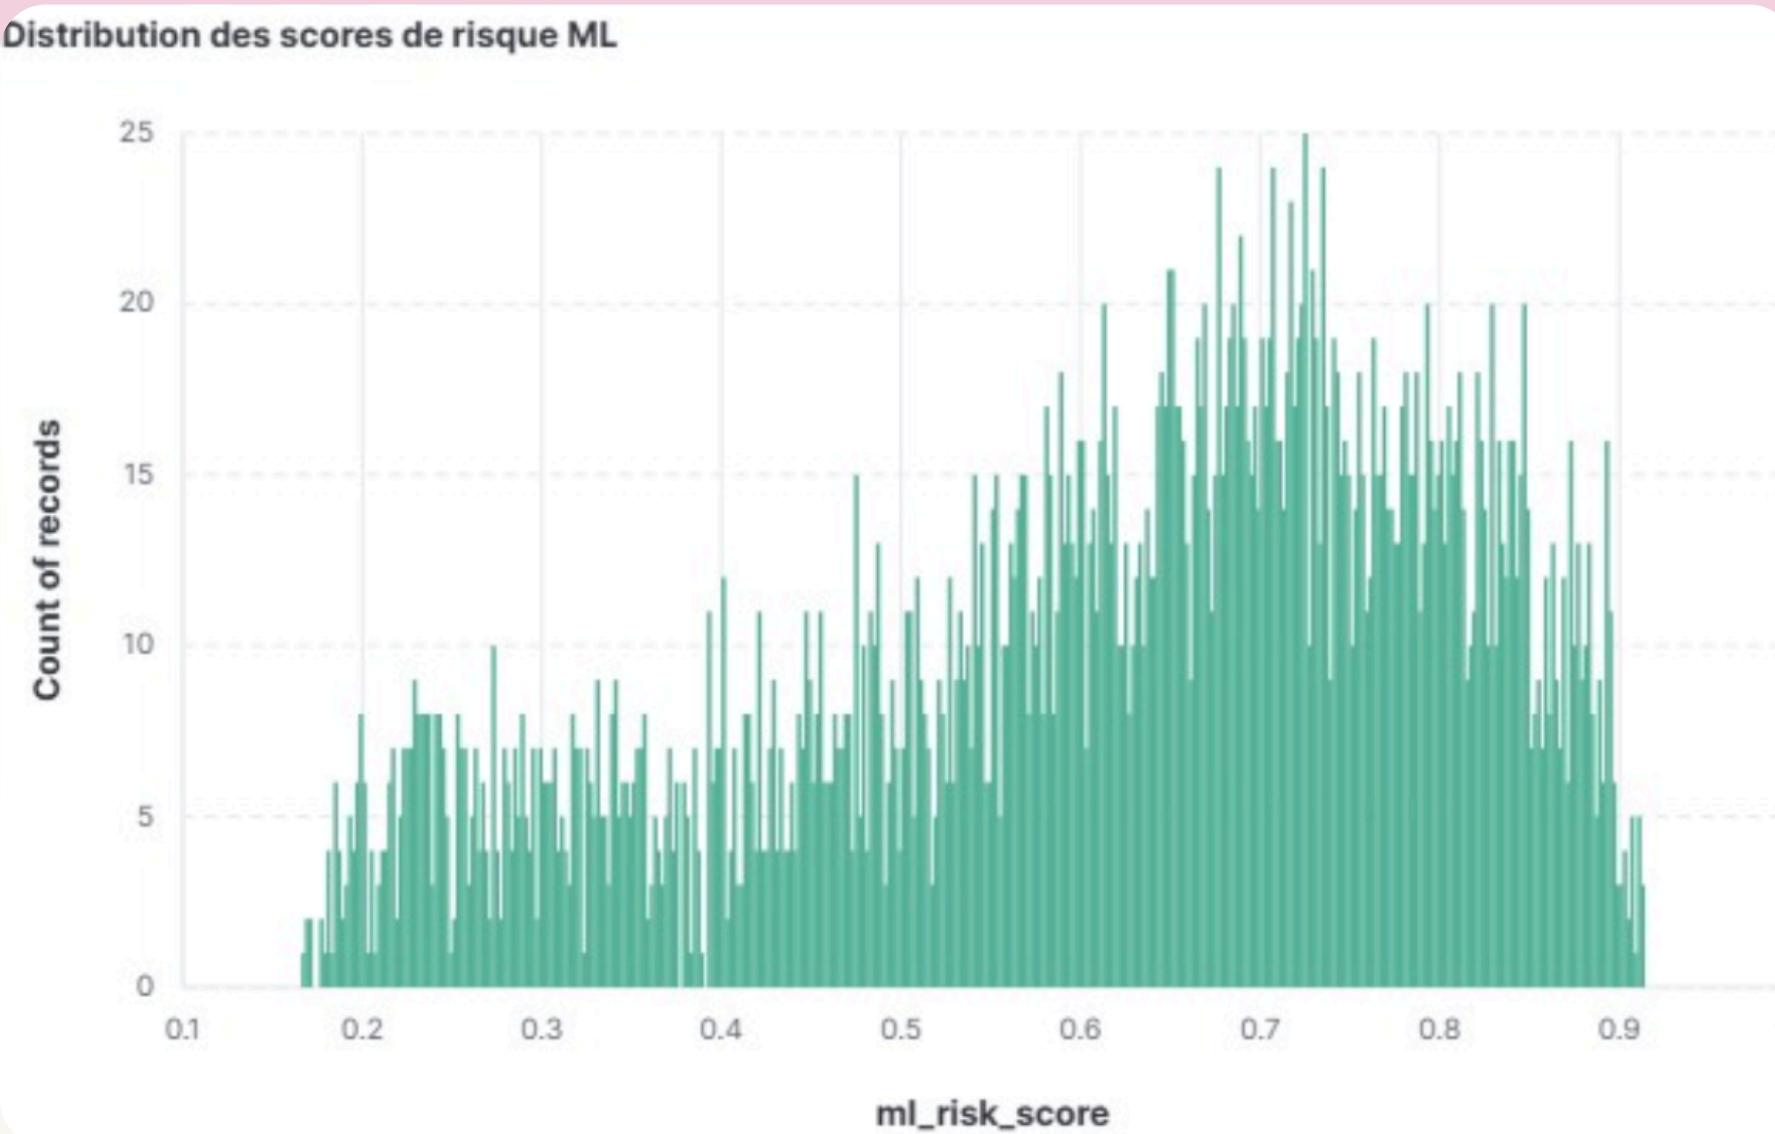


Évolution temporelle des anomalies de pression artérielle

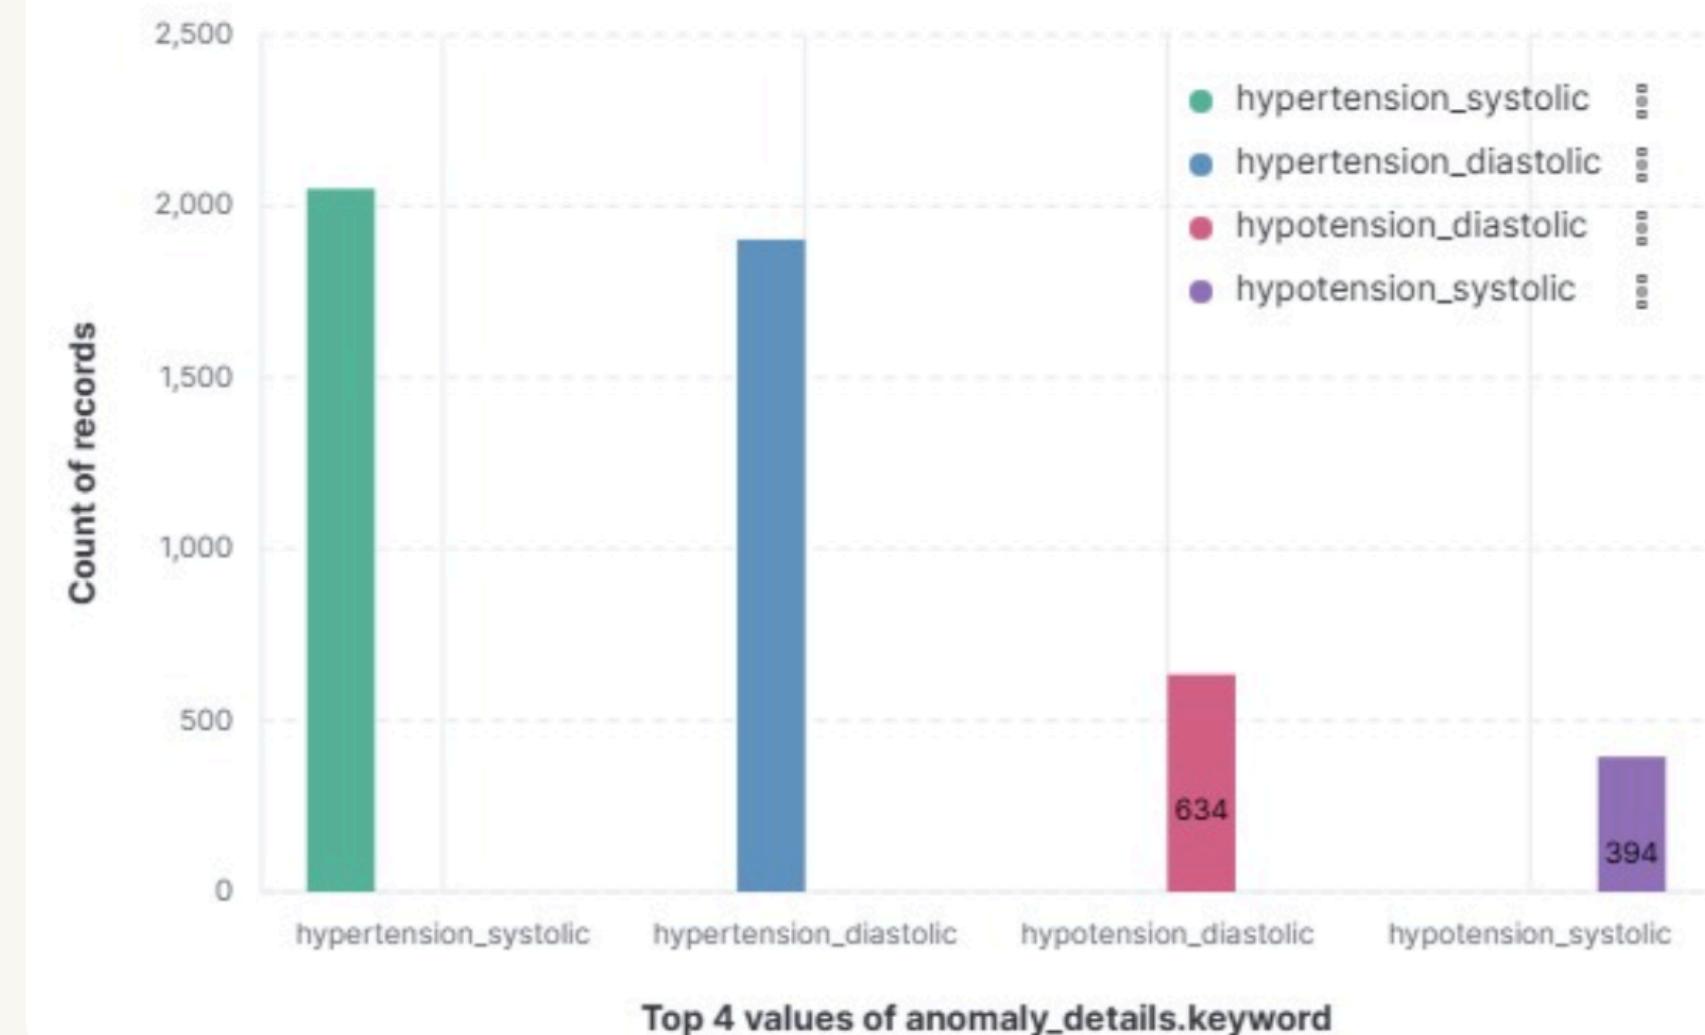


06 Visualisation et dashboards Kibana

Distribution des scores de risque ML



Répartition des types d'anomalies de pression artérielle

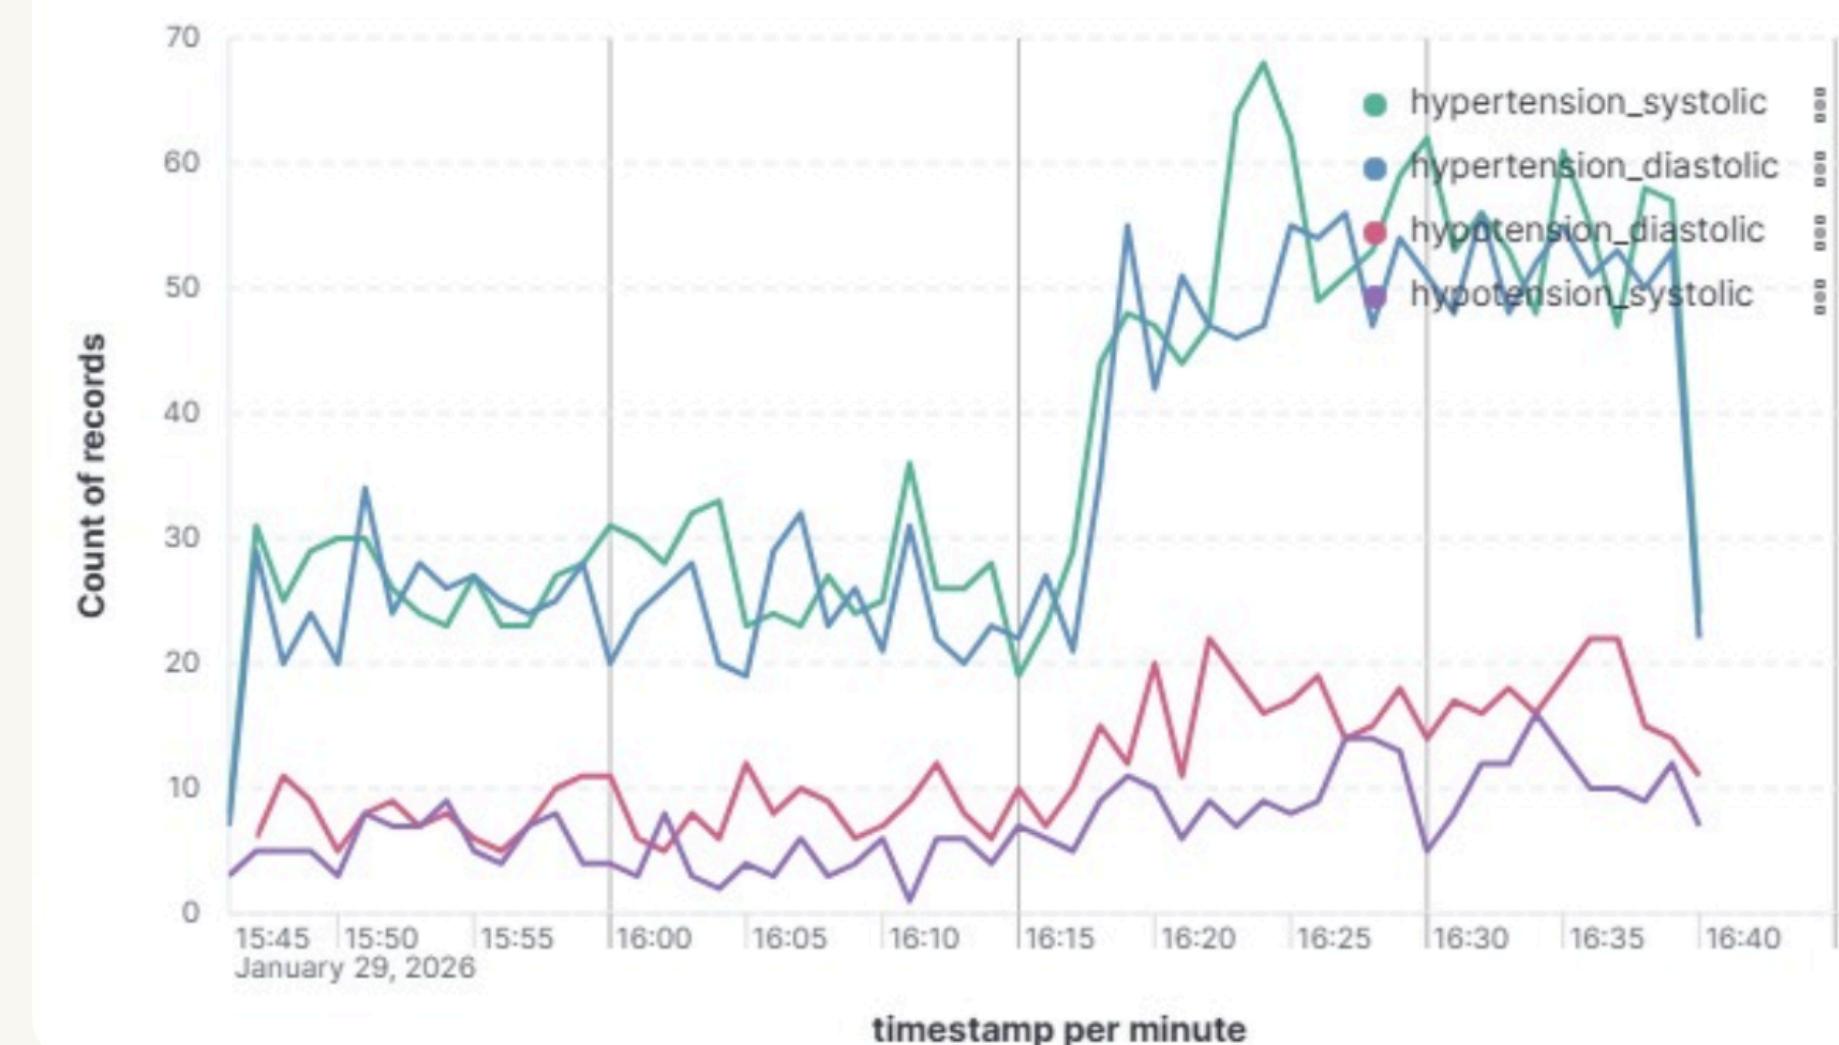


06 Visualisation et dashboards Kibana

Évolution du risque ML au cours du temps



Évolution temporelle des différents types d'anomalies de pression artérielle



06 Visualisation et dashboards Kibana

Liste des patients présentant des anomalies de pression artérielle				
patient_id.keyword	systolic_pressure	diastolic_pressure	anomaly_details	ml_risk_score
PAT-004	89	70	hypotension_systc	0.192
PAT-004	89	70	hypotension_systc	0.194
PAT-004	89	70	hypotension_systc	0.196
PAT-004	89	70	hypotension_systc	0.198
PAT-004	89	70	hypotension_systc	0.2
PAT-004	89	70	hypotension_systc	0.202
PAT-004	89	70	hypotension_systc	0.204
PAT-004	89	70	hypotension_systc	0.206
PAT-004	89	70	hypotension_systc	0.208
PAT-004	89	70	hypotension_systc	0.21

06 Visualisation et dashboards Kibana

Cas Critiques - alertes BP

14 documents

Columns 7 Sort fields 1

timestamp	patient_id	systolic_pressure	diastolic_pressure	anomaly_details
Jan 29, 2026 @ 22:43:43.451	PAT-004	150	117	[hypertension_systolic]
Jan 29, 2026 @ 22:43:43.450	PAT-003	152	116	[hypertension_systolic]
Jan 29, 2026 @ 22:43:43.449	PAT-002	149	118	[hypertension_systolic]
Jan 29, 2026 @ 22:43:43.448	PAT-001	176	107	[hypertension_systolic]

Cas critiques récents de pression artérielle

timestamp	patient_id.keyword	systolic_pressure	diastolic_pressure	anomaly_details
22:45:00	PAT-002	108	99	hypertension_dias
22:45:00	PAT-002	111	108	hypertension_dias
22:45:00	PAT-002	152	76	hypertension_syst
22:44:30	PAT-003	80	94	hypertension_dias
22:44:30	PAT-003	157	74	hypertension_syst
22:44:30	PAT-003	167	118	hypertension_dias
22:44:30	PAT-003	171	70	hypertension_syst
22:44:30	PAT-003	180	70	hypertension_syst
22:44:00	PAT-005	82	62	hypotension_syst
22:44:00	PAT-005	101	118	hypertension_syst

07 Système d'alertes en temps réel

4 rules

Name	Last run	Notify	In...	Duration	P50	Success r...	Last response	State
Alerte - Pic anomalies BP Index threshold	Jan 29, 2026 23:02:53pm 41 seconds ago	1 mi n	00:00 00:01	100%	● Succeeded	Enabled	...	
Alerte BP — Cas critique (systolique + diastolique) Elasticsearch query	Jan 29, 2026 23:02:53pm 41 seconds ago	1 mi n	00:00 00:01	100%	● Succeeded	Enabled	...	
Alerte BP — Hypertension diastolique Elasticsearch query	Jan 29, 2026 23:02:53pm 41 seconds ago	1 mi n	00:00 00:01	100%	● Succeeded	Enabled	...	
Alerte — Hypertension systolique Elasticsearch query	Jan 29, 2026 23:02:53pm 41 seconds ago	1 mi n	00:00 00:01	100%	● Succeeded	Enabled	...	

Alerte - Pic anomalies BP

Type Index threshold

Rule is Enabled

283 executions in the last 24 hr

Last response

● Succeeded

Notify when alerts generated

Definition

Rule type Index threshold

Actions

server-log-bp
On status changes

Description Alert when an aggregated query meets the threshold.

server-log-bp
On status changes

Runs every 1 min

Conditions 0 conditions

08 Limites et perspectives

Limites

- Données simulées (pas de données cliniques réelles)
- Modèle ML simple (régression logistique)
- Règles cliniques statiques (seuils fixes)
- Pas de gestion de l'historique patient
- Scalabilité limitée (Kafka & consumer simples)

Perspectives

- Utilisation de données réelles anonymisées
- Modèles ML plus avancés (Random Forest, XGBoost, LSTM)
- Analyse temporelle par patient
- Alertes personnalisées selon le profil patient
- Déploiement cloud & monitoring avancé

09 Conclusion

- Pipeline temps réel complet de bout en bout
- Intégration Data Engineering + Data Science
- Détection d'anomalies par règles cliniques +
Machine Learning
- Visualisation et alertes via Kibana
- Projet fonctionnel, modulaire et évolutif